

AI 基准防作弊速查表

自进化技能晋升门禁的判卷与成本双指标——防止「靠啰嗦通过考试」（2026-10 实战定案）

判卷：断言四模式（expect 子串语义向后兼容）

模式	拦截什么	要点
expect-exact	旧子串匹配放行「包含关键词但整体错误」	输出一字不差（首尾空白容忍）
expect-regex	形状漂移的输出	坏正则 = 判例错误 而非通过——门禁不许自欺
expect-none	啰嗦但错误（失败标记入文）	禁词表：如 "OHM OK (error ignored)"
expect-any	单一标准答案过严	多个可接受答案命中其一即可

成本：双指标门（只否决、不判分）

cand > max(base × 1.3, base + 8)

候选输出成本超过基线 1.3 倍且超出超 8 token → 成本回归出局。
estTokens: **CJK≈1 token/字**、**ASCII≈1/4**——换中文灌水同样绕不过。用例可 cost-cap: 覆写。

十连死实录：微型考题「等待中.....」期望输出仅 ~4 token——1.3 倍帽只留 1 token 余量，技能扰动一个字符即出局，**连续 10 个候选死在同一道门**。修复：+8 绝对余量地板，保住「真啰嗦是 2-10 倍」的判别力，放过针尖级扰动。

两条铁律：① 断言读代码围栏**内部**——模型在散文里改写、在围栏里逐字保留（day-55 发现），围栏是让「精确」可达成的话术约定；② 门禁本身要可测试——本规则由 10 个单元测试守护（含「换中文绕不过帽」「+8 地板」两个专项）。